

多模态触觉世界模型技术评估报告

Tactile × Video × Action × Language × Speech 技术路线领先性评估

评估日期：2026-09-04

评估对象：MoSense「触觉 × 世界模型」机器人多模态模型路线

评估方法：对 2026 年最新世界动作模型（WAM）与视觉-触觉-动作模型（VTA）代表性工作的系统性对标分析

参考来源：项目 docs/paper/ 5 篇论文 + awesome-vla-2026 全景（250+ 篇）+ 3 篇在线解读

目录

- 摘要
- 结论速览（抽取）
- 项目目标与技术定位
- 技术版图全景：VLA 与 WAM 的 2026
- 核心论文深度解读
- 与项目目标的对照分析
- 领先性评估（SWOT）
- 硬件短板深度分析
- 差异化路径建议
- 最终结论
- 算法壁垒与算力门槛
- 数据来源盘点（战略核心）
- 训练技巧清单（先学习后深究）
- 参考文献

一、摘要

MoSense 项目的最终目标是构建一个融合 **触觉（Tactile）**、**视频（Video）**、**动作（Action）**、**语言（Language）**、**语音（Speech）** 五模态的机器人控制模型，底层基于 LingBot-VA 的复现与 Fast-WAM 触觉扩展。本报告通过系统对标 2026 年 3—7 月间发布的核心工作，评估该路线的技术领先性与竞争格局。

核心判断：该路线在「方向选择」与「时间窗口」上处于正确位置——世界动作模型（WAM）刚刚被验证为视觉-语言-动作模型（VLA）的下一代范式，视觉-触觉世界模型则是 2026 年 7 月才密集涌现的最前沿方向。但在「硬件能力」与「原创性」两个维度上存在显著短板：项目所用的 Mosense 传感器为 15 维低分辨率霍尔阵列，与前沿工作普遍采用的 GelSight 高分辨率视觉触觉存在**硬件代差**；触觉×世界模型的赛道已被上科大 ViTacWorld、上交 VTAM 等占据，项目属于**追赶者与扩展者**而非开创者。

真正的胜负手在于：能否为「低维、低成本、可量产的霍尔触觉」找到一条 GelSight 高分辨率路线走不通的差异化整合路径。

二、结论速览（抽取）

以下是本报告抽取的核心结论，每一条在正文中有对应的数据与论文依据。

结论 1：世界模型路线正确，是 VLA 的下一代

Fast-WAM（清华 × Galaxea AI，2026.03）证明：世界动作模型**不需要测试时显式预测未来视频**，视频建模的价值主要在训练期学习物理先验。它在 LIBERO 达 **97.6%**、RoboTwin 达 **91.8%** 成功率，推理延迟仅 **190ms**（比想象-再-执行范式快 4× 以上）。项目选择复现 Fast-WAM，路线方向正确。

结论 2：触觉 × 世界模型是 2026 年最前沿，但已非空白

ViTacWorld（上科大，2026.07）、VTAM（上交 × UIUC，2026.06）等证明「触觉作为锚定信号进入预测性世界模型」能显著提升接触密集型任务成功率（VTAM 在薯片抓取 90%、黄瓜削皮 85%、白板擦拭 95%）。项目踩在正确的时间点，但**不是首创者**。

结论 3：最大短板是触觉硬件分辨率

前沿工作（ViTacWorld、VTAM、TAP-VLA）普遍使用 **GelSight 高分辨率视觉触觉传感器**，能计算光流、剪切场、虚拟力。而 MoSense 是 **5 路三轴霍尔 = 15 维**低分辨率磁场值，**无法支持** VTAM 的虚拟力正则化、TAP-VLA 的剪切场投影等关键技术。这是硬件代差，不是软件能弥补的。

结论 4：触觉整合方式比触觉本身更重要

TAP-VLA（密歇根，2026）的关键实验发现：加触觉编码器反而 **32% < 纯视觉 43% < 视觉标注 78%**。意味着低维触觉若以「加编码器硬塞进 VLA」的朴素方式整合，极可能重蹈 32% 的覆辙。整合方式必须系统性消融。

结论 5：五模态齐全（含语音）是真实差异化

awesome-vla-2026 全景显示，语音/音频进 VLA 的工作极少（VLAS、Shake-VLA 等），多传感器融合（OmniVLA、FuSe）也未覆盖「触觉+视频+动作+语言+语音」的完整组合。项目在模态齐全度上领先。

结论 6：综合定位 = 方向领先、时机正确、硬件短板致命、非首创

项目是「世界模型 × 触觉」浪潮中的**早期参与者**，但拼硬件分辨率拼不过 GelSight 路线，胜负手在于低维霍尔触觉的独特整合路径。

三、项目目标与技术定位

3.1 最终目标



3.2 底层技术栈

层	内容	状态
模型	Fast-WAM（复现）+ 触觉扩展	云端 150K 已训完（loss 0.126）
触觉	MoSense 5 路三轴霍尔（15 维）	真机数据流正常
语音	本地 Whisper 识别 + TTS	已跑通
硬件	SO-101 双臂 + 双相机	校准联调完成

3.3 定位判断

项目本质是「在清华 Fast-WAM 的世界模型框架上，加入自研低维触觉作为额外 observation，并扩展语音模态」。这决定了它的创新性质是**增量式扩展**，而非架构级原创。

四、技术版图全景：VLA 与 WAM 的 2026

4.1 VLA 基础范式演进

flowchart LR

```
RT1["RT-1/RT-2<br/>(2022-2023)<br/>Transformer 进机器人"] --> OpenVLA["OpenVLA<br/>(2024)<br/>首  
OpenVLA --> Pi0["π0 家族<br/>(2024-2026)<br/>flow-matching"]  
Pi0 --> WAM["World Action Models<br/>(2025-2026)<br/>显式建模世界演化"]  
WAM --> FastWAM["Fast-WAM<br/>(2026.03)<br/>免测试时想象"]  
WAM --> TactileWAM["触觉 WAM<br/>ViTacWorld/VTAM<br/>(2026.06-07)"]  
style WAM stroke-width:3px  
style TactileWAM stroke-width:3px,fill:#fef3c7
```

4.2 awesome-vla-2026 的 15 大技术维度

维度	代表工作	与项目相关性
基础范式	RT-2, OpenVLA, π0	★ 背景
Generalist VLA	CogACT, SmoVLA, RDT2	★ 竞争基线
架构 (AR/Diffusion/Flow/Dual/MoE/Mamba)	π0.7, HiRT, CogACT	★★★★ 选型参考
输入模态 · 3D/4D	SpatialVLA, PointVLA	★ 相机选型
输入模态 · 触觉/力	Tactile-VLA, ForceVLA, VLA-Touch	★★★★★ 直接对标
输入模态 · 语音	VLAS, Shake-VLA	★★★★ 差异化点
多传感器融合	OmniVLA, FuSe, OmniVTLA	★★★★ 直接对标
动作表征	FAST, LAPA, GR00T N1	★★ 触觉动作 token
推理 ECoT	ECoT, CoT-VLA, ThinkAct	★ 可选增强
Efficient VLA	TinyVLA, BitVLA, VLA-Cache	★★ 落地效率
RL 微调	VLA-RL, SimpleVLA-RL	★★ 后训练
数据/预训练	Open X-Embodiment, DROID	★★★ 数据来源
跨本体	X-VLA, UniVLA	★ 泛化
灵巧手	DexVLA, GR-RL	★ 下游
记忆/长程	MemoryVLA, MemER	★ 长程任务

4.3 ICLR 2026 九大趋势

- 1. 离散扩散 (Discrete diffusion)
- 2. 具身思维链推理 (ECoT)
- 3. 新动作 tokenizer
- 4. 效率优化
- 5. RL 微调
- 6. 视频预测 (Video prediction) ← 与 WAM 路线共振
- 7. Benchmark 革新
- 8. 跨本体迁移
- 9. 记忆与组合

关键观察：视频预测（WAM 的核心）是 ICLR 2026 的九大趋势之一，且触觉/力模态是输入模态扩展的活跃分支。项目方向与学术界大势共振。

五、核心论文深度解读

5.1 Fast-WAM (清华 × Galaxea AI, arXiv:2603.16666, 2026.03)

一句话：世界动作模型不需要测试时「想象未来」，视频建模的价值在训练期。

核心问题：现有 WAM 走「想象-再-执行」(imagine-then-execute) 范式，测试时迭代视频去噪带来巨大延迟；但没人验证「显式未来想象」是否真的必要。

方法：提出 Fast-WAM，训练时保留视频 co-training（学物理先验），测试时跳过未来预测。并实例化多个变体做受控消融：

- Fast-WAM-Joint（联合建模）
- Fast-WAM-IDM（逆动力学）
- 去除视频 co-training 的对照

实验结果：

基准	Fast-WAM	对比
RoboTwin	91.8%	超 Motus(无预训练 87.8%/有 77.3%)、LingBot-VA(无预训练 80.6%)，接近 LingBot-VA(预训练 92.2%)
LIBERO	97.6%	超 $\pi 0.5$ ，接近 LingBot-VA 98.5%、Motus 97.7%
延迟	190ms	RTX 5090D，比想象-再-执行快 4× 以上

关键消融：去除视频 co-training 导致性能大幅下降，而测试时跳过未来预测几乎不影响性能。**结论：**视频预测的主要价值在训练期的世界表征，而非测试期生成未来观测。

对项目的意义：这是项目复现的底座，路线已验证。项目的「触觉扩展」正是往 Fast-WAM 的 cross-attention context 里加入触觉时序（design 文档 § 3.3 已规划）。

5.2 HarmoWAM（北大，arXiv:2605.10942，2026.05）

一句话：调和「想象-再-执行」与「联合建模」两种 WAM 范式的 trade-off。

核心发现：两种范式有根本 trade-off——想象-再-执行显式利用世界模型，泛化好但交互精度差；联合建模动作精细但受训练分布探索空间约束。

方法：HarmoWAM 端到端自适应融合两种范式。

对项目的意义：说明 WAM 范式内部仍在快速演进。项目当前复现的是 Fast-WAM 的「联合建模」路线，需关注 HarmoWAM 的自适应思路是否值得吸收。

5.3 ViTacWorld（上科大，arXiv:2607.22530，2026.07）——最直接对标

一句话：动作条件化的视觉-触觉世界模型，首个用世界模型做 visuo-tactile-action 轨迹生成与策略评估。

核心问题：接触丰富任务中触觉是关键模态（非补充信号），但真实触觉数据采集昂贵、硬件依赖、任务多样性差。

方法：

1. 利用公开真实触觉数据 + 仿真环境（TacSL/TacEx/UniVTAC）扩展 visuo-tactile-action 数据
2. 关键洞察：触觉信号直接植根于物理接触，**sim-to-real gap 比纯视觉小**
3. 先大规模预训练真实+仿真轨迹，再用真机 rollout 微调
4. 给定动作，预测时序对齐的视觉观测 + 触觉反馈

双重角色：

- **合成 rollout** → 数据增强 → 改进下游触觉策略
- **策略评估** → 在受控动作序列下预测动作条件化的视觉-触觉结果

对项目的意义：这是与项目路线几乎重合的工作（视觉-触觉世界模型 + 动作条件化）。但它用的是 GelSight 类高分辨率触觉，且强调「仿真数据 + 世界模型预测触觉」的规模化路径——这是项目可以借鉴、但硬件上暂时跟不上的地方。

5.4 VTAM（上交 × UIUC，arXiv:2603.23481，2026.06）

一句话：Video-Tactile-Action Model，触觉作为锚定信号进预测性世界模型，超越 VLA。

核心问题：VAM 在长周期视觉任务优秀，但接触丰富场景中关键交互状态仅凭视觉部分可观测（夹持器遮挡、微小形变/滑动不可见）。

方法三大贡献：

- 1. **预测性触觉整合：**把触觉作为互补锚定信号进预测性世界模型，非简单反应式融合
- 2. **虚拟力正则化（防模态塌陷）：**从触觉光流推导 3D 虚拟力（切向力=表面图案位移，法向力=流散度），作为辅助监督，防止模型过度依赖高维视觉忽略触觉
- 3. **高效跨模态学习：**轻量模态迁移微调，无需触觉-语言配对数据

实验结果：

任务	VTAM 成功率	对比 $\pi 0.5$ 基线
薯片抓取-放置	90%	高 80%（基线仅 ~50%）
黄瓜削皮	85%	弯曲表面需稳定接触力
白板擦拭	95%	倾斜表面法向力调节

对项目的意义：验证了「触觉进预测性世界模型」的价值。但其**虚拟力正则化依赖 GelSight 光流**，MoSense 的 15 维霍尔无法复现这一关键组件。

5.5 TAP-VLA（密歇根，arXiv:2606.29089，2026.06）—— 关键教训

一句话：触觉标注提示——不改架构，把剪切场投影成颜色叠加到 RGB，让 VLA「看到」力。

核心问题：VLA 对接触力不敏感；触觉难整合进 VLA（大规模预训练语料缺触觉，引入新模态造成分布偏移）。

方法：

- 1. GelSight 视觉触觉传感器提取剪切场（Farneback 光流）
- 2. 把剪切场作为空间定位向量（颜色黄→红表强度）投影叠加到多视角 RGB
- 3. 保持输入为 RGB，避免架构修改和分布偏移

实验结果（四个接触密集任务）：

方法	总体成功率
TAP-VLA（视觉标注）	78%
仅视觉微调	43%
加触觉图像	44%
加触觉编码器	32%

核心结论：提供触觉信息的方式与信息本身同样重要。加编码器路线（如 OmniVTLA）反而低于纯视觉，归因于分布偏移；视觉标注保持视觉骨干能理解的颜色/空间关系，最小化预训练分布改变。

对项目的意义：这是对项目最直接的方法论警示——MoSense 低维触觉若走「加触觉编码器」路线，极可能得到 32% 的下场。必须设计低维触觉的独特注入方式（如世界模型预测触觉 latent、或接触状态 token），而不是朴素加 encoder。

5.6 PACE（北大，arXiv:2606.00537，2026.05）

一句话：相位感知的 chunk 执行，解决动作分块的固定 horizon 限制。

核心问题：VLA/diffusion 策略用 action chunking，但执行 horizon（每条 chunk 执行多少步）是固定超参，无法适配任务不同相位。

方法：PACE 预测最优执行 horizon，在仿真和真机任务上提升成功率。

对项目的意义：动作分块的执行策略优化，属于工程层改进，可后续参考。

5.7 Exploiting Policy Idling（DeepMind，arXiv:2508.15669，2025.08）

一句话：PIP 方法，利用策略「idling」（怠速/卡死）的检测来做探索和策略改进。

核心问题：学习策略常在某些状态「idle」（不再移动），反映训练数据缺陷（如高精度动作区数据量少）。

方法：Pause-Induced Perturbations（PIP），在检测到 idling 时施加扰动引导探索。

对项目的意义：接触密集任务（插入、抓取）正是 idling 高发场景，PIP 可作为策略改进的补充手段。

六、与项目目标的对照分析

6.1 模态覆盖度对照

模态	Fast-WAM	ViTacWorld	VTAM	TAP-VLA	MoSense 目标
视频 Video	×	■	■	■ (RGB)	■
动作 Action	×	×	×	×	■
语言 Language		—	—		
触觉 Tactile		(GelSight)	(GelSight)	(GelSight)	(霍尔 15 维)
语音 Speech					

模态	Fast-WAM	ViTacWorld	VTAM	TAP-VLA	MoSense 目标
世界模型预测		(预测触觉)			(设计目标)

观察：MoSense 目标在**模态数量**上最全（唯一同时含语音 + 触觉 + 世界模型预测），但在**触觉感知质量**上最弱（15 维 vs GelSight）。

6.2 技术路线对照



关键差异：两条路线都通向「触觉进世界模型」，但起点（传感器）不同，决定了上层方法不可直接移植。

七、领先性评估（SWOT）

7.1 Strengths（优势）

项	说明
方向正确	WAM 路线被 Fast-WAM 验证，触觉×世界模型是 2026 最前沿
时机正确	处于浪潮早期，还有差异化空间
模态齐全	五模态（含语音）组合唯一
真机闭环	SO-101 真机 + 触觉 + 双相机已跑通，非纯仿真
低成本触觉	霍尔阵列可量产、可嵌入，是 GelSight 做不到的

7.2 Weaknesses（劣势）

项	说明
硬件代差	15 维 vs GelSight 高分辨率，无法用光流/虚拟力

项	说明
非首创	ViTacWorld/VTAM 已占据视觉触觉世界模型
增量创新	Fast-WAM + 触觉是扩展，非架构原创
数据规模	云端 150K 步 vs 前沿动辄十亿级预训练

7.3 Opportunities（机会）

项	说明
低维触觉差异化	便宜可量产 → 大规模数据采集，走 GelSight 走不了的规模化
语音模式	端到端语音指令是空白点
世界模型预测低维触觉	预测接触状态而非触觉图像，绕开分辨率瓶颈
接触判别专项	contact/empty_grasp 判别是高价值低垂果实

7.4 Threats（威胁）

项	说明
赛道拥挤	上科大、上交、密歇根、北大密集进入
硬件迭代慢	GelSight 类传感器持续降价/开源
巨头发力	若 OpenVLA/ $\pi 0$ 加入触觉，小团队难竞争

八、硬件短板深度分析

8.1 传感器能力对照

维度	GelSight 视觉触觉	MoSense 霍尔阵列
原理	弹性体 + 标记 + 相机	磁铁 + 三轴霍尔芯片
输出	高分辨率触觉图 ($H \times W$)	$5 \times 3 = 15$ 维磁场值
可提取特征	光流、剪切场、虚拟力、接触几何	接触/无接触、粗力度
成本	高（精密相机+弹性体）	低（可量产）
可嵌入性	差（体积大）	好（可集成到夹爪）
数据 sim-to-real	需专门仿真（TacSL 等）	磁场可近似物理建模

8.2 关键结论

MoSense 15 维信号无法支撑三类前沿技术：

1. VTAM 的虚拟力正则化（需光流推导切向/法向力）
2. TAP-VLA 的剪切场投影（需高分辨率位移场）
3. ViTacWorld 的触觉流预测（需触觉图像序列）

但 15 维霍尔有独特价值：

- 直接输出「接触/无接触/空抓」低维判别，无需图像处理
- 可低成本大规模部署，数据采集规模化
- 磁场信号可物理建模，sim-to-real 潜力

8.3 项目 design 文档的定位是否合理？

项目 `tactile-world-model-design.pdf` 已明确：「当前传感器不是高密度触觉阵列，第一阶段只用于判断 no_contact / contact_active / possible_grasp / empty_grasp」。这个定位是清醒且正确的——它避开了和 GelSight 硬拼分辨率，转而聚焦低维但关键的接触判别。

九、差异化路径建议

9.1 核心策略：扬长避短

不拼高分辨率触觉图像（拼不过），主打「低维霍尔 + 世界模型 + 可量产」的独特组合。

9.2 四条具体路径

路径一：世界模型预测低维触觉 latent（推荐主攻）

- 在 Fast-WAM 基础上，预测未来触觉 latent（而非触觉图像）
- 对接 design 文档「视觉历史 + 霍尔时序 + proprio + action → 低维接触状态/未来触觉 latent/动作 chunk」
- 这是 ViTacWorld「预测触觉」的低维版本，绕开分辨率瓶颈

路径二：接触状态 token 注入（学 TAP-VLA 的教训）

- 不做朴素触觉编码器，而是把 15 维霍尔映射为「接触状态 token」注入 cross-attention
- 系统消融：低维注入 vs 编码器 vs 世界模型预测，找出最优整合方式

路径三：语音端到端指令（真差异化）

- 明确语音定位：是「指令接口」还是「模态融合」？
- 若走模态融合（语音特征进模型），是 VLAS/Shake-VLA 之外少有人做的方向

路径四：低成本规模化数据采集

- 霍尔触觉便宜可量产 → 快速铺开多臂、多任务采集
- 用数据规模弥补硬件分辨率劣势（数据量大 + 低维信号，可能达成 GelSight 走不了的规模效应）

9.3 需要规避的坑

1. **不要朴素加触觉编码器**（TAP-VLA 的 32% 教训）
2. **不要宣称超越 GelSight 路线**（硬件代差客观存在）
3. **不要只做架构增量**（Fast-WAM + 触觉 是追赶，要找到独有贡献点）

十、最终结论

10.1 一句话总结

方向领先、时机正确、硬件短板致命、非首创。 项目是「世界模型 × 触觉」浪潮中的早期参与者，方向与 2026 年学术前沿完全共振，但真正的胜负手在于——能否为「15 维低分辨率霍尔触觉」找到一条 GelSight 高分辨率路线走不通的差异化整合路径。

10.2 三句话行动纲领

1. **守住世界模型路线**：Fast-WAM 已验证，继续做触觉扩展，但聚焦「预测低维触觉 latent」而非触觉图像
2. **接受硬件定位**：不拼分辨率，主打低维接触判别 + 可量产规模化，这是 GelSight 做不到的
3. **做真差异化**：语音模态融合 + 低维触觉的世界模型预测，是两个可以建立壁垒的点

10.3 风险提示

若未来 6-12 个月内 GelSight 类传感器大幅降本 + 开源触觉世界模型普及，项目的硬件差异化优势可能被压缩。届时需评估是否转向「高分辨率触觉 + 世界模型」的主流路线。

十一、算法壁垒与算力门槛

11.1 核心结论：算力不是壁垒，数据才是

来自 roboticscenter.ai 《Scaling VLA Model Training on a Budget》的 100+ 次微调经验：**训练资源不是瓶颈，瓶颈是「干净、标注良好、分桶正确的演示数据」**。在加大模型之前先把数据集翻倍（300→600 条精选演示的性价比，远高于把模型从 1B 升到 7B）。

这个结论对战略决策是决定性的：**别在算力上烧钱，把钱和时间花在数据上。**

11.2 从零训练 vs 微调（算力天壤之别）

方式	算力门槛	说明
从零训练 7B VLA	基本不可行	预算巨大到「让微调变得无意义」，仅全新动作空间才考虑
微调（LoRA）OpenVLA 7B	单 H100 一夜完成	可训练参数减少 ~100 倍
微调（QLoRA）	A100 40GB 即可	4-bit 量化再省一半显存
Octo（小模型）	消费级 24GB (3090/4090)	一个下午跑完

11.3 GPU 选择对照

GPU	显存	能干什么
RTX 3090/4090	24GB	Octo 舒适，OpenVLA QLoRA 小 batch
A6000/L40S	48GB	OpenVLA QLoRA 舒适、LoRA 可跑
A100 40GB	40GB	QLoRA 舒适，LoRA 勉强
A100/H100 80GB	80GB	LoRA 舒适，大 batch
RTX PRO 6000（本地）	96GB	本地最强的消费级，LoRA + 大 batch 无压力

11.4 项目算力现状与定位

项	现状
本地 GPU	RTX PRO 6000 Blackwell 96GB （lingbot 占 31G，剩 ~60G）

项	现状
云端 GPU	A800 80GB（FastWAM 150K 步训了 ~4 天）
结论	算力足够微调路线，不够从零训练 7B 级

战略含义：项目应走「微调开源基座 + 用别人的数据」路线，而非从零训练。这正好与「用别人数据」的战略诉求完全契合。

11.5 低预算训练技巧速查（详见第十三章）

LoRA/QLoRA、FlashAttention-2、梯度检查点、bf16 混合精度、梯度累积、torch.compile、云 spot 实例（省 40-70%）。

十二、数据来源盘点（战略核心）

12.1 通用机器人数据集

数据集	规模	说明
Open X-Embodiment	140 万轨迹 / 22 本体 / 150K 任务	全球最大开源机器人数据集，RT-X 的底座
DROID	大规模真实双臂操作	灵巧操作
RH20T	真实+仿真混合	带语言标注
BridgeData V2	厨房/家居操作	谷歌

12.2 触觉数据集（项目最需要的一类）

数据集	内容	来源
VTouch	超 6 万分钟跨本体视触觉数据集（全球首个，为 VTLA 提供基准）	国地中心
UniVTAC	仿真视触觉数据 + 传感器仿真	GitHub univtac/UniVTAC
tactile-video-pretrain	触觉视频预训练数据集（SOURCES.md 汇总多个源）	HF yxma/tactile-video-pretrain
SoftVTBench	可变形物体视触觉基准（arXiv 2608.18701）	—
Hoi!	力基多模态关节操作（arXiv 2512.04884）	—
GelSLAM_dataset	GelSight SLAM 数据	HF joehjhuang/ GelSLAM_dataset

数据集	内容	来源
ManiFeel	视触觉策略学习基准	普渡

12.3 仿真数据（规模化关键）

平台	用途
LIBERO	最常用 short-horizon 基准（4 套件 × 10 任务 × 500 演示）
RoboTwin 2.0	双臂操作（Fast-WAM 评测用）
RoboCasa	家居任务大规模生成
MimicGen	从少量演示自动生成大规模数据
SynGrasp-1B	十亿级抓取数据
TacSL / TacEx / UniVTAC	触觉传感器仿真（ViTacWorld 用）

12.4 人类视频数据（动作先验）

数据集	用途
Ego4D	第一视角人类视频 → 动作先验
Epic-Kitchens	厨房操作视频

12.5 战略建议：用别人数据的路径

```
flowchart TB
    D1["通用: Open X-Embodiment<br/>140万轨迹"] --> F["微调 Fast-WAM / VLA 基座"]
    D2["触觉: VTouch 6万分钟<br/>+ UniVTAC 仿真"] --> F
    D3["仿真: MimicGen 数据增强<br/>+ RoboTwin"] --> F
    D4["自采: MoSense 霍尔<br/>低成本规模化"] --> F
    F --> G["接触密集操作策略"]
    style D2 fill:#fef3c7
    style D4 fill:#fef3c7
```

- 三条落地路径：
- 1. 直接用触觉公开数据（VTouch 6 万分钟）做触觉模态预训练/微调——但注意：这些多为 GelSight 高分辨率数据，与 MoSense 15 维霍尔模态不匹配，不能直接吃，需做模态对齐或仅借鉴训练策略
 - 2. 用通用数据打底（Open X-Embodiment）+ 自采触觉数据（MoSense 低成本）微调——这是最现实的组合
 - 3. 仿真补量：MimicGen 从少量自采演示生成大规模变体；UniVTAC 做触觉仿真

关键警示：触觉公开数据几乎都是 GelSight 视觉触觉，与 MoSense 霍尔是**不同传感器模态**，无法直接迁移。这是「用别人的触觉数据」这一战略的最大障碍——别人的触觉数据你未必用得上，除非做跨传感器对齐。

十三、训练技巧清单（先学习，后深究）

13.1 参数高效微调（重中之重）

技巧	作用	优先级
LoRA（rank 16-32）	冻结基座，可训练参数降 ~100 倍	★★★★★
QLoRA（4-bit）	显存再减半	★★★★★
模态迁移微调	VTAM 用触觉增强预训练视频 Transformer，无需触觉-语言配对	★★★★★

13.2 显存与效率优化

技巧	作用
FlashAttention-2	注意力显存降 3-4 倍，提速 20-40%（「not optional」）
梯度检查点	峰值显存降 ~2 倍，吞吐损失 20-30%
bf16 混合精度	Ampere/Hopper 首选，优化器保持 fp32
梯度累积	凑有效 batch 64-128
torch.compile	零改动提速 10-25%
云 spot 实例	省 40-70%，每 15-30 分钟 checkpoint

13.3 触觉专项技巧（对标论文提炼）

技巧	来源	说明
虚拟力正则化	VTAM	用触觉光流推导 3D 虚拟力做辅助监督，防「模态塌陷」
触觉标注提示（不改造架构）	TAP-VLA	剪切场投影到 RGB，避免分布偏移
世界模型预测触觉 latent	ViTacWorld / design 文档	预测未来触觉而非反应式融合
接触状态 token 注入	design 文档	低维霍尔映射为接触状态 token

13.4 动作与执行优化

技巧	来源	说明
Action Chunking	ACT	一次预测未来动作序列
PACE 相位感知执行	北大 2026	动态调整 chunk 执行 horizon
PIP 怠速扰动	DeepMind	检测 idling 引导探索，改进高精度动作区

13.5 后训练强化

技巧	来源	说明
RL 微调	VLA-RL / SimpleVLA-RL	2025-2026 爆发期，真机 rollout 后 RL 提升成功率

十四、参考文献

#	论文	机构/时间	arXiv
1	Fast-WAM: Do World Action Models Need Test-time Future Imagination?	清华 × Galaxea AI, 2026.03	2603.16666
2	HarmoWAM: Harmonizing Generalizable and Precise Manipulation via Adaptive World Action Models	北大, 2026.05	2605.10942
3	ViTacWorld: Scaling Visuo-Tactile World Models for Contact-Rich Robot Manipulation	上科大, 2026.07	2607.22530
4	VTAM: Video-Tactile-Action Models for Complex Physical Interaction Beyond VLAs	上交 × UIUC, 2026.06	2603.23481
5	TAP-VLA: Tactile Annotation Prompting for Vision Language Action Models	密歇根, 2026.06	2606.29089
6	PACE: Phase-Aware Chunk Execution for Robot Policies with Action Chunking	北大, 2026.05	2606.00537
7	Exploiting Policy Idling for Dexterous Manipulation (PIP)	DeepMind, 2025.08	2508.15669
8	awesome-vla-2026	miracle-techlink	GitHub

报告完 • 2026-09-04